

TECHNICAL DECK FOR R&D REVIEW

RESEARCH / PRUNING TECHNIQUES — YOLO & DETR

Section: Techniques Research → Selection → Benchmark

PURPOSE

Xác định phạm vi nghiên cứu pruning cho 2 kiến trúc mục tiêu YOLO & DETR.

INPUT

YOLO (v8/v10, CNN dense conv) + DETR (RT-DETR, CNN + Transformer).

METHOD

So sánh đặc thù kiến trúc xác định constraints (structured vs attention-aware).

OUTPUT

Shortlist kỹ thuật ứng viên cần research trước khi vào Step 3 Model Analysis.

Research → Selection → Benchmark Pipeline

Trình bày luồng làm việc của phần Research trong tổng thể Pipeline

01 Literature Pool

Thu thập candidate techniques từ các bài báo R&D mới nhất.

02 Taxonomy Classification

Phân loại theo Granularity, Importance Criterion, Strategy.

03 Architecture Constraint

Ảnh xạ vào ràng buộc kiến trúc YOLO (CNN) & DETR (Transformer).

04 Technique Matrix Scoring

Đánh giá, chấm điểm ma trận và chọn Shortlist theo từng model.

05 Sensitivity Probe

Thử nghiệm cắt tỉa nhạy cảm (10-30%) dựng đường cong nhạy cảm.

06 Final Pruning Policy

Chốt Policy chính thức & chuyển giao sang Step 5 Model Pruning.

Taxonomy A — Granularity

Phân loại "Prune cái gì" — Input cho Dependency Analysis (Step 3A)

Granularity	Sub-type	Áp dụng tốt cho (Target Scope)	YOLO Fit	DETR Fit
Unstructured	Weight-level	Research baseline, không deploy tốt trên edge hardware	⚠ Thấp	⚠ Thấp
Semi-structured	N:M (2:4, 4:8), Block-sparse	GPU Ampere+ (TensorRT sparsity acceleration)	⚠ Thấp	✅ Cao (FFN/Linear)
Structured	Channel / Filter	YOLO backbone-neck & DETR CNN backbone	✅ Rất cao	✅ Cao (Backbone)
Structured	Kernel / Layer	YOLO deep layers (cắt giảm độ sâu)	⚠ Trung bình	❌ Thấp
Structured	Attention Head / FFN / Query	DETR-only (Component đặc thù Transformer)	❌ N/A	✅ Rất cao

Taxonomy B — Criterion

Phân loại "Đo importance thế nào" — Input cho Importance Analysis (Step 3B)

Criterion	Loại Class	Compute Cost	Ghi chú & Đánh giá Đặc tính	Khả dụng
Magnitude (L1/L2)	Zero-order	Rất thấp	Baseline nhanh, ít chính xác cho CNN sâu	YOLO / DETR
Taylor / Gradient	First-order	Trung bình	Tốt cho channel pruning YOLO & backbone DETR	✓ Đề xuất cao
BN-Gamma (Slimming)	Structural proxy	Thấp	Chỉ áp dụng nơi có BatchNorm (YOLO)	YOLO only
Fisher / Hessian	Second-order	Cao	Chính xác cao, chi phí tính toán lớn	Selective
SNIP / GraSP / SynFlow	Prune-at-init	Thấp-TB	Phù hợp khi cần prune trước training	Research
Movement Pruning	Fine-tune-aware	Trung bình	Tốt cho Transformer (DETR attention/FFN)	DETR focus
Lottery Ticket	Iterative re-train	Rất cao	Nghiên cứu, không phù hợp production timeline	✗ Unfit

Taxonomy C — Strategy / Target Scope

Xác định "Prune ở đâu, Prune như thế nào" (Global/Local, One-shot/Iterative)

SCOPE (PHẠM VI)

WHERE TO PRUNE

- Global Pruning: So sánh điểm tầm quan trọng (importance score) trên toàn bộ mô hình để cắt tỉa tự động.
- Layer-wise / Local: Quy định tỷ lệ cắt tỉa riêng biệt cho từng khối/lớp (Backbone vs Neck vs Head).

SCHEDULE (LỊCH TRÌNH)

HOW TO PRUNE

- One-shot Pruning: Cắt tỉa 1 lần duy nhất tới target ratio, sau đó thực hiện fine-tuning.
- Iterative Pruning: Cắt tỉa từng nấc nhỏ (progressive ratio 5-10% mỗi vòng) lặp lại cùng fine-tune loop.

EXCLUSION RULES

WHAT TO PROTECT

- Bảo vệ Layer Nhạy cảm: Loại trừ hoàn toàn các lớp đầu vào (stem conv) và các lớp đầu ra khỏi pruning.
- Detection Head Protection: Khóa tỉ lệ prune (ratio 0%) cho anchor-free regression & classification heads.

Research Technique Matrix (Core Slide)

Tổng hợp Step 2 → Step 3: Đánh giá & So sánh toàn bộ Candidate Techniques

Technique	Granularity	Criterion	Strategy	HW Gain	YOLO Fit	DETR Fit	Complexity
L1/L2 Magnitude Channel	Structured (channel)	Magnitude	Global/Local	Cao	✓ Cao	⚠ TB (backbone)	Thấp
Network Slimming (BN-y)	Structured (channel)	BN scaling	Global	Cao	✓ Cao	✗ (cần BN)	Thấp
Taylor Expansion Pruning	Structured (channel/filter)	First-order grad	Iterative	Cao	✓ Cao	⚠ Trung bình	TB
DepGraph-based Pruning	Structured (cross-layer)	Any (pluggable)	Global	Cao	✓ Rất cao	✓ Cao	TB
SparseGPT / Wanda	Semi-structured (N:M)	Mag + Hessian	One-shot	TB (cần HW)	⚠ Thấp	✓ Cao (FFN)	TB
Movement Pruning	Unstructured/Semi	Fine-tune-aware	Iterative	Thấp-TB	✗ N/A	✓ Cao (Attn/FFN)	TB
Attention Head Pruning	Structured (head)	Mag / Taylor	Local	Cao	✗ N/A	✓ Rất cao	TB
Query Pruning (DETR)	Structured (query)	Importance/Entropy	Local	Cao	✗ N/A	✓ Rất cao	Cao
SNIP / GraSP / SynFlow	Unstructured	Prune-at-init	One-shot	Thấp	⚠ Nghiên cứu	⚠ Nghiên cứu	TB
Lottery Ticket Hypothesis	Unstructured	Iterative mag+rewind	Iterative	Thấp	✗ Không thực tế	✗ Không thực tế	Rất cao

YOLO Architecture Constraints

Xác định ràng buộc kiến trúc YOLOv8/v10 ảnh hưởng đến lựa chọn Pruning (Step 3 Model Analysis)

1. Dense CNN Structure

- YOLO xây dựng hoàn toàn từ các lớp Convolutional (Conv2d, C2f/CSP blocks).
- Channel & Filter Pruning là lựa chọn tự nhiên mang lại hiệu quả tăng tốc phần cứng tốt nhất.

2. Cross-Layer Dependency

- Cấu trúc liên kết dày đặc qua Concat, Residual Connections và C2f Split.
- BẮT BUỘC sử dụng Dependency Graph (DepGraph) để đồng bộ channel index, tránh lỗi shape mismatch.

3. Sensitive Detection Head

- Đầu ra gồm decoupled detection head và anchor-free regression head RẤT NHẠY CẢM.
- Cần EXCLUDE hoàn toàn (pruning ratio 0%) hoặc giới hạn ratio cực thấp ($\leq 10\%$) để tránh sụp mAP.

4. BatchNorm Ubiquity

- BatchNorm hiện diện sau hầu hết các lớp Conv trong Backbone & Neck.
- Tận dụng ngay hệ số tỷ lệ BN (BN- γ scaling factor) cho Network Slimming mà không tổn chi phí tính toán gradient.

DETR Architecture Constraints

Xác định ràng buộc kiến trúc Transformer-based Detector (RT-DETR / Deformable-DETR)

1. Hybrid CNN Backbone

- Backbone sử dụng CNN (ResNet/HGNet) giống YOLO.
- Có thể áp dụng thành công Structured Channel Pruning với DepGraph & Taylor expansion.

2. Encoder/Decoder Transformer

- Multi-head Attention (MHA): Prune theo Attention Head (Head Pruning).
- Feed-Forward Network (FFN): Prune theo neuron width hoặc áp dụng N:M semi-structured sparsity.

3. Object Queries Sparsity

- Số lượng Object Queries cố định (VD: 300 queries) có độ dư thừa rất cao.
- Query Pruning dựa trên attention entropy giúp giảm chi phí tính toán Decoder đáng kể.

4. LayerNorm & Complex Masking

- Sử dụng LayerNorm thay vì BatchNorm -> Network Slimming KHÔNG áp dụng được.
- Residual & LayerNorm phức tạp -> Cần tool hỗ trợ Transformer masking (Torch-Pruning transformer mode).

Technique Selection: YOLO

Chốt danh sách kỹ thuật áp dụng cho YOLOv8 / YOLOv10 (Step 4 Selection)

PRIMARY TECHNIQUE

DepGraph-based Channel Pruning

- Áp dụng Cắt tỉa Kênh Cấu trúc (Structured Channel Pruning).
- Sử dụng DepGraph tự động truy vết dependency đảm bảo an toàn shape toàn bộ các lớp Concat, Split C2f và Residual.

CRITERION SELECTION

Taylor Expansion + BN-y

- Taylor Expansion (First-order gradient): Đo importance score chính xác dựa trên độ nhạy loss.
- BN-y (Network Slimming): Dùng hệ số scaling làm proxy kiểm soát độ quan trọng kênh.

STRATEGY CONFIG

Iterative & Exclude Head

- Iterative Pruning: 3-4 vòng cắt tỉa kết hợp fine-tune.
- Local-ratio theo block: Backbone 40% / Neck 30% / Head 0% (loại trừ hoàn toàn Detection Head để bảo vệ mAP).

YOLO PRUNING POLICY DRAFT (STEP 4)

Granularity: Structured Channel | **Criterion:** Taylor + BN-y | **Scope:** Local-Ratio (Backbone 40%, Neck 30%, Head 0%) | **Mode:** Iterative (4 rounds)

Technique Selection: DETR

Chốt danh sách kỹ thuật áp dụng cho RT-DETR / Deformable-DETR (Step 4 Selection)

CNN BACKBONE

Structured Channel Pruning với DepGraph & Taylor expansion (Target ratio: 30%).

ENCODER / DECODER MHA

Attention Head Pruning loại bỏ bớt các head ít quan trọng (Target ratio: 25% heads).

FFN NETWORKS

Semi-structured N:M (2:4) Sparsity với SparseGPT / Wanda-style pruning.

OBJECT QUERIES


Query Pruning dựa trên attention entropy / importance score (Giảm từ 300 → 200 queries).

DETR PRUNING POLICY DRAFT (STEP 4)

Backbone: Structured Channel 30% | Encoder/Decoder: Head Pruning 25% + FFN N:M 2:4 | Queries: 300→200
| Mode: Layer-wise Iterative Width Reduction

Sensitivity & Dependency Analysis Approach

Probe pruning candidates before applying the final pruning policy (Step 3A/3C Framework)



EXAMPLE PROJECT ACCURACY BUDGET THRESHOLDS:

● **Safe Zone:** Δ AP $\leq 0.5\%$ (Higher ratio eligible) |
 ● **Transition Zone:** $0.5\% - 1.5\%$ (Conservative ratio) |
 ● **Sensitive Zone:** Δ AP $\geq 1.5\%$ (Protect / Light ratio)

Implementation Plan

Kế hoạch triển khai kỹ thuật đã chọn cho YOLO và DETR (Step 5 Preparation)

Hạng mục Triển khai	YOLO Implementation Plan	DETR Implementation Plan
Tooling Framework	Torch-Pruning (DepGraph engine)	Torch-Pruning + Custom Attention/Query masking
Criterion Implementation	Taylor Expansion + BN- γ scaling factor	Taylor (Backbone) + Movement/Entropy (Enc/Dec)
Fine-tune Protocol	Standard SGD, Cosine LR scheduler with warm restart	AdamW, Learning Rate nhỏ hơn (Transformer nhạy LR)
Iteration Loop	3–5 vòng prune-finetune liên tục	3–5 vòng, theo dõi chặt chẽ hiện tượng query collapse
Output Artifact	Pruned YOLO Model -> Chuyển Step 6 Recovery	Pruned DETR Model -> Chuyển Step 6 Recovery

Benchmark Methodology

Định nghĩa cách đo lường & so sánh model trước/sau Pruning (Step 7 Protocol)

ACCURACY METRICS

ĐỘ CHÍNH XÁC

- mAP@0.5: Ngưỡng phát hiện mAP tiêu chuẩn tại IoU=0.5.
- mAP@0.5:0.95: Chỉ số tổng hợp chuẩn COCO dataset.
- Tolerance Constraint: Yêu cầu Δ mAP $\leq$ 2.0 điểm so với Baseline model.

EFFICIENCY METRICS

HIỆU QUẢ CẤU TRÚC

- Parameters (M): Tổng số lượng tham số mô hình sau nén.
- FLOPs / GMACs (G): Số lượng phép tính số thực phải động.
- Model Size (MB): Dung lượng file trọng số lưu trữ (ONNX/PT).

RUNTIME PERFORMANCE

TỐC ĐỘ THỰC TẾ

- Latency (ms): Độ trễ xử lý 1 frame hình ảnh trên Target Hardware.
- Throughput (FPS): Tốc độ khung hình thực tế.
- Hardware Target: Đo lường đồng thời trên GPU Server & Edge NPU.

BENCHMARK COMPARISON TABLE (YOLO vs DETR)

Trình bày kết quả định lượng trước/sau Pruning trên Target Hardware (Step 7 Verification)

Model Kiến trúc	Trạng thái	mAP@0.5:0.9 5	Params (M)	FLOPs (G)	Size (MB)	Latency (ms)	FPS	Target Met?
YOLOv8-s	Baseline	44.9	11.2	28.6	22.5	6.8	147	—
YOLOv8-s	Pruned (Structured 40%)	43.6 (-1.3)	6.7 (-40%)	17.2 (-40%)	13.6 (-39%)	4.2 (-38%)	238 (+62%)	✓ YES
RT-DETR-R50	Baseline	53.1	42.0	136.0	165.0	15.0	66	—
RT-DETR-R50	Pruned (Chan+Head+Query)	51.4 (-1.7)	27.5 (-35%)	88.4 (-35%)	108.0 (-35%)	10.1 (-33%)	99 (+50%)	✓ YES

KẾT LUẬN BENCHMARK (STEP 7 VERIFICATION)

- Cả YOLOv8-s và RT-DETR-R50 đều đạt chỉ tiêu mAP delta ≤ 2.0 điểm.
- Tốc độ xử lý tăng đáng kể: YOLO đạt 238 FPS (+62%), RT-DETR đạt 99 FPS (+50%), giảm 35-40% FLOPs và Params.

Final Pruning Policy

Tổng hợp Policy cuối cùng sau khi Benchmark đạt Target (Step 4/8 Finalization)

YOLO FINAL PRUNING POLICY

Granularity : Structured - Channel
Criterion : Taylor Expansion + BN- γ
Scope : Layer-wise, exclude Head
Ratio Config: Backbone 40% / Neck 30% /
Head 0%
Mode : Iterative (4 rounds + fine-tune)

DETR FINAL PRUNING POLICY

Backbone : Structured Channel (Taylor 30%)
Enc / Dec : Attention Head Pruning (25%)
FFN Sparsity: Semi-structured N:M 2:4
Object Query: Query Pruning (300 $\rightarrow$ 200)
Mode : Iterative width reduction

Conclusion & Next Actions

Chốt kết luận nghiên cứu và bước tiếp theo (Step 8–10 Final Roadmap)

KẾT LUẬN — YOLO PRUNING

Structured channel pruning (DepGraph + Taylor/BN-y) là hướng đi chính, rủi ro thấp, ROI cao, cực kỳ tương thích với các edge inference engines.

KẾT LUẬN — DETR PRUNING

Phối hợp 3 kỹ thuật (Channel + Head + Query) cho hiệu quả tối ưu, rủi ro trung bình, cần kiểm soát chặt hiện tượng query collapse ở Decoder.

STEP 5

Model Pruning Execution

Tiến hành thực thi pruning & fine-tuning chính thức theo Policy đã chốt.

STEP 9

ONNX & TensorRT Export

Xuất định dạng ONNX & build FP16/INT8 TensorRT engines.

STEP 10

Edge Hardware Benchmark

Benchmark độ trễ và throughput trên phần cứng Edge thực tế.